


1. Identificación por Mínimos Cuadrados

1. <i>Mínimos Cuadrados</i>	1
1.1. Introducción	2
1.2. Método de Identificación por Mínimos Cuadrados	3
1.2.1. Forma Recursiva;	7
1.2.2. Inclusión del Factor de Olvido.	11
1.3. Características Estadísticas de la Estimación	14
1.4. Referencias	26

1.1. Introducción

ajuste *automático* de parámetros = *Identificación de Sistemas*



1.2. Método de Identificación por Mínimos Cuadrados

Se considera, a los efectos del análisis, la siguiente planta real:

$$y_k = \sum_{i=1}^n a_i y_{k-i} + \sum_{i=0}^m b_i u_{k-i-1} + \varepsilon_k = \mathbf{x}_k^T \boldsymbol{\theta}_k + \varepsilon_k \quad [1-1]$$

ε_k perturbación o incertidumbre.

modelo:

$$\hat{y}_k = \sum_{i=1}^n \hat{a}_i y_{k-i} + \sum_{i=0}^m \hat{b}_i u_{k-i-1} = \mathbf{x}_k^T \hat{\boldsymbol{\theta}}_k \quad [1-2]$$

donde

$$\boldsymbol{\theta}_k = \begin{bmatrix} a_1 \\ \vdots \\ a_n \\ b_0 \\ \vdots \\ b_m \end{bmatrix}_{1 \times N = n+m+1} \quad \hat{\boldsymbol{\theta}}_k = \begin{bmatrix} \hat{a}_1 \\ \vdots \\ \hat{a}_n \\ \hat{b}_0 \\ \vdots \\ \hat{b}_m \end{bmatrix}_{1 \times N = n+m+1} \quad \mathbf{x}_k = \begin{bmatrix} y_{k-1} \\ \vdots \\ y_{k-n} \\ u_{k-1} \\ \vdots \\ u_{k-m-1} \end{bmatrix}_{1 \times N = n+m+1} \quad [1-3]$$

Para cada instante k habrá un error o diferencia entre ambas salidas:

$$e_k = y_k - \hat{y}_k \quad [1-4]$$

tomando todas las muestras,

$$\mathbf{E}_k = \begin{bmatrix} e_k \\ \vdots \\ e_1 \end{bmatrix} = \mathbf{Y}_k - \Phi_k \hat{\boldsymbol{\theta}} \quad [1-5]$$

con

$$\mathbf{Y}_k = \begin{bmatrix} y_k \\ \vdots \\ y_1 \end{bmatrix}, \hat{\boldsymbol{\theta}} = \begin{bmatrix} \hat{a}_1 \\ \vdots \\ \hat{a}_n \\ \hat{b}_0 \\ \vdots \\ \hat{b}_m \end{bmatrix}, \Phi_k = \begin{bmatrix} \mathbf{x}_k^T \\ \vdots \\ \mathbf{x}_0^T \end{bmatrix} = \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-1} & \cdots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \cdots & y_{1-n} & u_0 & \cdots & u_{-m} \end{bmatrix} \quad [1-6]$$


Se puede minimizar el error respecto a $\hat{\theta}$.

$$J_k = \mathbf{E}_k^T \mathbf{E}_k \quad [1-7]$$

$$\nabla_{\theta} J|_{\hat{\theta}} = 2\Phi^T \mathbf{Y} - 2\Phi^T \Phi \hat{\theta} = \mathbf{0} \quad [1-8]$$

el valor de $\hat{\theta}$ que hace mínimo J es:

$$\hat{\theta}_k^* = \left[\Phi_k^T \Phi_k \right]^{-1} \Phi_k^T \mathbf{Y}_k \quad [1-9]$$





1.2.1. Forma Recursiva:

Analicemos una forma más cómoda de expresar la ecuación [1-9]. Primero definamos la matriz $\mathbf{P}$ como sigue:

$$\left[\Phi_k^T \Phi_k \right] = \mathbf{P}_k^{-1} = \begin{bmatrix} \mathbf{x}_k & \cdots & \mathbf{x}_0 \end{bmatrix} \begin{bmatrix} \mathbf{x}_k^T \\ \vdots \\ \mathbf{x}_0^T \end{bmatrix} = \sum_{i=0}^k \mathbf{x}_i \mathbf{x}_i^T = \mathbf{P}_{k-1}^{-1} + \mathbf{x}_k \mathbf{x}_k^T \quad [1-10]$$

Del mismo modo el vector $\mathbf{b}$ será:

$$\mathbf{b}_k = \Phi_k^T \mathbf{Y}_k = \begin{bmatrix} \mathbf{x}_k & \cdots & \mathbf{x}_0 \end{bmatrix} \begin{bmatrix} y_k \\ \vdots \\ y_0 \end{bmatrix} = \sum_{i=0}^k \mathbf{x}_i y_i = \mathbf{b}_{k-1} + \mathbf{x}_k y_k \quad [1-11]$$

Entonces [1-9] se expresará

$$\hat{\boldsymbol{\theta}}_k^* = \left[\Phi_k^T \Phi_k \right]^{-1} \Phi_k^T \mathbf{Y}_k = \mathbf{P}_k \mathbf{b}_k \quad [1-12]$$

La inversa de la matriz $\mathbf{P}_k$ en un instante k puede expresarse en función de su valor anterior más otra matriz

$$\mathbf{P}_k^{-1} = \mathbf{P}_{k-1}^{-1} + \mathbf{x}_k \mathbf{x}_k^T \quad [1-13]$$

Si la premultiplicamos por $\mathbf{P}_k$

$$\mathbf{P}_k \mathbf{P}_k^{-1} = \mathbf{I} = \mathbf{P}_k \mathbf{P}_{k-1}^{-1} + \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \quad [1-14]$$

y luego, posmultiplicando por $\mathbf{P}_{k-1}$ resulta:

$$\mathbf{P}_{k-1} = \mathbf{P}_k + \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \quad [1-15]$$

o lo que es lo mismo

$$\mathbf{P}_{k-1} - \mathbf{P}_k = \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \quad [1-16]$$

Posmultipliquemos [1-15] por $\mathbf{x}_k$

$$\mathbf{P}_{k-1} \mathbf{x}_k = \mathbf{P}_k \mathbf{x}_k + \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k = \mathbf{P}_k \mathbf{x}_k \left[1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k \right] \quad [1-17]$$

y agrupemos.

$$\mathbf{P}_{k-1} \mathbf{x}_k \left[1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k \right]^{-1} = \mathbf{P}_k \mathbf{x}_k \quad [1-18]$$

Ahora, reemplazando [1-18] en [1-16]

$$\mathbf{P}_{k-1} - \mathbf{P}_k = \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \quad [1-19]$$

o su equivalente

$$\mathbf{P}_k = \mathbf{P}_{k-1} - \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \quad [1-20]$$

Haremos lo mismo con el vector θ . Por la ecuación [1-18] tenemos

$$\hat{\theta}_k = \left[\mathbf{P}_{k-1} - \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \right] [\mathbf{b}_{k-1} + \mathbf{x}_k y_k] \quad [1-21]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} [\mathbf{b}_{k-1} + \mathbf{x}_k y_k] + \mathbf{P}_{k-1} \mathbf{x}_k y_k \quad [1-22]$$

por [1-18] sabemos que:

$$\mathbf{P}_k \mathbf{x}_k = \frac{\mathbf{P}_{k-1} \mathbf{x}_k}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \quad [1-23]$$

reemplazando en la anterior

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{b}_{k-1} - \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k y_k + \mathbf{P}_{k-1} \mathbf{x}_k y_k \quad [1-24]$$

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \hat{\theta}_{k-1} + \left[\mathbf{P}_{k-1} - \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \right] \mathbf{x}_k y_k \quad [1-25]$$

de [1-16] resulta

$$\mathbf{P}_k = \mathbf{P}_{k-1} - \mathbf{P}_k \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1} \quad [1-26]$$

quedando

$$\hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_{k-1} - \mathbf{P}_k \mathbf{x}_k \left[\mathbf{x}_k^T \hat{\boldsymbol{\theta}}_{k-1} - y_k \right] \quad [1-27]$$

en resumen, el algoritmo está formado por las dos ecuaciones siguientes:

$$\begin{cases} \hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_{k-1} - \mathbf{P}_k \mathbf{x}_k \left[\hat{y}_k - y_k \right] \\ \mathbf{P}_k = \mathbf{P}_{k-1} - \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{1 + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \end{cases} \quad [1-28]$$

Otra forma equivalente que se suele utilizar en la bibliografía es

$$\begin{cases} \mathbf{K}_k = \mathbf{P}_k \mathbf{x}_k \frac{1}{1 + \mathbf{x}_k^T \mathbf{P}_k \mathbf{x}_k} \\ \mathbf{P}_{k+1} = \mathbf{P}_k - \mathbf{K}_k \mathbf{x}_k^T \mathbf{P}_k \\ \hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_{k-1} + \mathbf{K}_k \left[y_k - \mathbf{x}_k^T \hat{\boldsymbol{\theta}}_{k-1} \right] \end{cases} \quad [1-29]$$

1.2.2. Inclusión del Factor de Olvido.

En el algoritmo anterior pesamos de igual manera las medidas muy viejas y las nuevas.

$$\mathbf{J}_k = \mathbf{E}_k^T \mathbf{Q} \mathbf{E}_k \quad [1-30]$$

donde

$$\mathbf{Q}_k = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & \alpha & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \alpha^{k-N} \end{bmatrix} \quad [1-31]$$

La matriz Q pondera las muestras dándole más o menos importancia a la historia con respecto al último valor según el parámetro α el cual se llama factor de olvido.

Igual que antes derivamos J para obtener el mínimo.

$$\nabla_{\theta} J|_{\hat{\theta}} = 2\Phi^T Q Y - 2\Phi^T Q \Phi \hat{\theta} = 0 \quad [1-32]$$

resultando

$$\hat{\theta}_k^* = \left[\Phi_k^T Q_k \Phi_k \right]^{-1} \Phi_k^T Q_k Y_k \quad [1-33]$$

Forma recursiva:

$$\begin{cases} \hat{\theta}_k = \hat{\theta}_{k-1} - \mathbf{P}_k \mathbf{x}_k [\hat{y}_k - y_k] \\ \mathbf{P}_k = \frac{1}{\alpha} \left[\mathbf{P}_{k-1} - \frac{\mathbf{P}_{k-1} \mathbf{x}_k \mathbf{x}_k^T \mathbf{P}_{k-1}}{\alpha + \mathbf{x}_k^T \mathbf{P}_{k-1} \mathbf{x}_k} \right] \end{cases} \quad [1-34]$$

o lo que es lo mismo

$$\left\{ \begin{array}{l} \mathbf{K}_k = \mathbf{P}_k \mathbf{x}_k \frac{1}{\alpha + \mathbf{x}_k^T \mathbf{P}_k \mathbf{x}_k} \\ \mathbf{P}_{k+1} = \frac{1}{\alpha} \left[\mathbf{P}_k - \mathbf{K}_k \mathbf{x}_k^T \mathbf{P}_k \right] \\ \hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_{k-1} + \mathbf{K}_k \left[y_k - \mathbf{x}_k^T \hat{\boldsymbol{\theta}}_{k-1} \right] \end{array} \right. \quad [1-35]$$

1.3. Características Estadísticas de la Estimación

$$\Phi_k^T \Phi_k = \begin{bmatrix} y_{k-1} & \cdots & y_0 \\ \vdots & & \vdots \\ y_{k-n} & \cdots & y_{1-n} \\ u_{k-1} & \cdots & u_0 \\ \vdots & & \vdots \\ u_{k-m} & \cdots & u_{-m} \end{bmatrix} \bullet \begin{bmatrix} y_{k-1} & \cdots & y_{k-n} & u_{k-1} & \cdots & u_{k-m} \\ \vdots & & \vdots & \vdots & & \vdots \\ y_0 & \cdots & y_{1-n} & u_0 & \cdots & u_{-m} \end{bmatrix} \quad [1-36]$$

autocovarianza o covarianza cruzada

$$\Phi_k^T \Phi_k (1,1) = y_{k-1}^2 + \cdots + y_0^2 = \sum_{i=0}^{k-1} y_i^2 = r_y(0) \quad [1-37]$$

La matriz total se llama matriz de covarianza del algoritmo y será:

$$\Phi_k^T \Phi_k = \begin{bmatrix} r_y(0) & \dots & r_y(n-1) & r_{uy}(n-m-1) & \dots & r_{uy}(n-1) \\ \vdots & & \vdots & \vdots & & \vdots \\ \vdots & & \vdots & r_{uy}(n-1) & \dots & r_{uy}(n-m-1) \\ r_{uy}(n-m-1) & \dots & r_{uy}(n-1) & r_u(0) & \dots & r_u(m) \\ \vdots & & \vdots & \vdots & & \vdots \\ r_{uy}(n-1) & \dots & r_{uy}(n-m-1) & r_u(m) & \dots & r_u(0) \end{bmatrix} \quad [1-38]$$

media de $\hat{\boldsymbol{\theta}}$.

$$\begin{aligned} \lim_{k \rightarrow \infty} E[\hat{\boldsymbol{\theta}}_k] &= \lim_{k \rightarrow \infty} E\left[\left[\Phi_k^T \Phi_k\right]^{-1} \Phi_k^T \mathbf{Y}_k\right] = E[\hat{\boldsymbol{\theta}}_k] \\ &= \lim_{k \rightarrow \infty} E\left[\left[\Phi_k^T \Phi_k\right]^{-1} \Phi_k^T [\Phi_k \boldsymbol{\theta} + \boldsymbol{\varepsilon}_k]\right] \quad [1-39] \end{aligned}$$

$$= \lim_{k \rightarrow \infty} E[\boldsymbol{\theta}] + \lim_{k \rightarrow \infty} E\left[\left[\Phi_k^T \Phi_k\right]^{-1} \Phi_k^T \boldsymbol{\varepsilon}_k\right]$$

$$E[\hat{\boldsymbol{\theta}}_k] = E[\boldsymbol{\theta}] + E\left[\left[\Phi_k^T \Phi_k\right]^{-1} \Phi_k^T \boldsymbol{\varepsilon}_k\right] \quad [1-40]$$

Por lo tanto, la media de la estimación coincidirá con el valor real de θ si el error e es incorrelado con $[\Phi_k^T \Phi_k]^{-1} \Phi_k^T$. En cualquier otro caso existirá un sesgo en la estimación.

También debemos notar que para que exista solución la matriz $[\Phi_k^T \Phi_k]$ debe ser invertible, o sea

$$\det [\Phi_k^T \Phi_k] \neq 0 \quad [1-41]$$

Observando la ecuación 0 podemos inferir que esto se puede lograr si el sistema está persistentemente excitado.

Ejemplo 1. Sistema de Primer Orden.

Para familiarizarnos un poco más con el funcionamiento del estimador veamos un ejemplo sencillo. Sea un sistema de primer orden cuya ecuación en diferencias es:

$$y_k = a y_{k-1} + b u_{k-1} \quad [1-42]$$

con $a = 0,5$ y $b = 1$

k	y_k	u_k
0	0	1
1	$b = 1$	1
2	$b(1 + a) = 1,5$	1
3	$b(1 + a + a^2) = 1,75$	1
4	$b(1 + a + a^2 + a^3) = 1,875$	1

El vector Φ será, para tres muestras,

$$\Phi = \begin{bmatrix} 1,75 & 1 \\ 1,5 & 1 \\ 1 & 1 \end{bmatrix} \quad [1-43]$$

su transpuesta,

$$\Phi^T = \begin{bmatrix} 1 & 1 & 1 \\ 1,75 & 1,5 & 1 \end{bmatrix} \quad [1-44]$$

el vector de medidas de la salida,

$$\mathbf{Y}_k = \begin{bmatrix} 1,875 \\ 1,75 \\ 1,5 \end{bmatrix} \quad [1-45]$$

la matriz de covarianza,

$$\Phi^T \Phi = \begin{bmatrix} 6,3125 & 4,25 \\ 4,25 & 3 \end{bmatrix} \quad [1-46]$$

la matriz $\mathbf{P}$:

$$\left[\Phi^T \Phi \right]^{-1} = \begin{bmatrix} 3.4286 & -4.8571 \\ -4.8571 & 7.2143 \end{bmatrix} \quad [1-47]$$

y finalmente el vector

$$\Phi^T \mathbf{Y} = \begin{bmatrix} 7,4063 \\ 5,125 \end{bmatrix} \quad [1-48]$$

Con estos datos ya podemos calcular la estimación de los dos parámetros del sistema resultando obviamente,

$$\hat{\boldsymbol{\theta}} = \left[\Phi_k^T \Phi_k \right]^{-1} \Phi_k^T \mathbf{Y}_k = \begin{bmatrix} 0,5 \\ 1 \end{bmatrix} \quad [1-49]$$

Ejemplo 2. Medición de una Resistencia

Se mide Tensión y Corriente sobre una resistencia

$$u_{mk} = u_k + e_{uk} \quad (1.50)$$

$$i_{mk} = i_k + e_{ik}$$

la medición de la resistencia es

$$r_{mk} = \frac{u_{mk}}{i_{mk}} \quad [1.51]$$

por mínimos cuadrados


$$J = E_k^T E_k = (U - rI)^T (U - rI) \quad (1.52)$$

$$\frac{\partial J}{\partial r} = -2I^T (U - rI) = 0 \quad (1.53)$$


$$r_{mc} = \frac{I^T U}{I^T I} \quad (1.54)$$

Cálculo de r

```
n=1000;  
vi=1;  
vu=1;  
i=1+vi*(rand(n,1)-.5);  
u=1+vu*(rand(n,1)-.5);  
r=zeros(n,1);  
for k=1:n  
    r(k)=u(1:k)'*i(1:k)/(i(1:k)'*i(1:k));  
end  
plot(r);grid  
axis([0 n -.5 1.5])  
cov(i);
```



```
plot(u./i);grid;  
axis([0 n -0.5 1.5])
```



```
[mean(r) mean(u./i) cov(r) cov(u./i)]
```

```
ans =
```

```
0.9211    1.0816    0.0021    0.2293
```

Sesgo

$$\begin{aligned}
 E(r_{mc}) &= E \left\{ \frac{I_m^T U_m}{I_m^T I_m} \right\} = E \left\{ \frac{(I_r + e_i)^T (U_r + e_u)}{(I_r + e_i)^T (I_r + e_i)} \right\} \\
 &= E \left\{ \frac{I_r^T U_r}{(I_r + e_i)^T (I_r + e_i)} \right\} = \frac{r}{1 + \frac{\sigma_i^2}{I_r^T I_r}}
 \end{aligned} \tag{1.55}$$

Método de mínimos cuadrados es


$$\hat{\theta} = [\phi^T \phi]^{-1} \phi^T Y \tag{1.56}$$

$$E(\hat{\theta}) = E \left\{ [\phi^T \phi]^{-1} \phi^T (\phi \theta + e) \right\} \tag{1.57}$$

el error está en la salida. No hay error en la entrada

Variables instrumentales

```
rvi=zeros(n,1);  
L=2;  
ivi=i;  
ivi(1:length(i)-L)=i(L+1:length(i));  
for k=1:n  
    rvi(k)=u(1:k)'*ivi(1:k)/(i(1:k)'*ivi(1:k));  
end
```



1.4. Referencias

- i. Ljung, Lennart: System Identification: Theory for the User, 2nd Edition, Prentice Hall, Englewood Cliffs, N.J.,1999. p 313
- ii. Goodwin, G. Sin: *Adaptive Filtering, Prediction and Control*, Prentice Hall – 1984. p 52
- iii. Åström, K., Wittenmark: *Adaptive Control*, Prentice Hall – 1989. p 69
- iv. Landau, Ioan Doré. **System Identification and Control Design** – Prentice Hall – 1990
- v. Isermann, R.: *Digital Control Systems*, Springer Verlag – 1981. p 380